소음진동과 산업인공지능

시각화 기반 딥러닝 분석 기술

이재성, 김기환, 이충기, 고성안*
(울산과학기술원)

1. 머리말

오늘날 딥러닝 기술은 다양한 종류의 패턴 인식 문제에서 인간에 필적하는, 또는 때때로 능가하는 모습을 보여주고 있다. 기존 기계학습 모형과 달리 딥러닝은 데이터에서 복잡한 특성을 반복된 학습을 통하여 자동적으로 추출하고 이를 모델의 의사결정 수단으로 사용한다. 딥러닝은 자율주행, 음성인식, 기계번역 등 여러 분야에서 이미 성능을 입증하였고 산업계에서도 점차 이용범위를 확대하고 있다. 그러나 딥러닝에도 단점이 존재하는데, 그것은 딥러닝 기술 내부 각 계층의 의사결정 과정을 인간이 이해하기 어렵다는 것이다. 이를 해결하기 위하여, 딥러닝 프로세싱 과정을 해석하기 위한 연구가 여러 학계와 산업계에서 다방면으로 진행되고 있다. 이 글에서는 지난 10월에 열린 IEEE VIS 시각화 기술 학회에서 발표된 딥러닝 시각화 및 해석 기술들 중, CNN, RNN을 위한 시각화 기술과, FACEBOOK이 자체 개발한 딥러닝 해석용 시각화 기술을 소개하고자 한다.

2. CNN에 관한 시각적 해석

CNN(convolutional neural network)은 합성곱 연산을 이용하여 2차원 혹은 3차원 공간의 이미지의 특징을 뽑아내어 분류하는데 사용되는 딥러닝 모델의 한 종류로, 이미지의 특징을 뽑는 방식 및 학습 과정의 해석이 매우 어렵다. 이는 곧 모델 간 비교, 수정, 개선에 어려움이 있음을 의미한다. 이를 극복하기 위한 방법으로 Pezzotti와 그의 동료들은 중간 은닉 계층들의 상태를 시각화하는 DeepEyes 시각화 시스템을 제안하였다[1]. DeepEyes는 은닉계층들과 필터, 네트워크로부터 추출된 학습 데이터의 패턴들과 학습에 필요한 또는 불필요한 계층들을 시각화를 통하여 나타내어준다. 따라서 이 시스템을 활용하면, 딥러닝의 학습이 어떻게 진행되고 있는지, 어떠한 특징들이 모델로부터 추출되었는지, 그리고 모델에 필요한 혹은 불필요한 계층이 어느 곳인지가 명확하게 드러나, 모델을 이해하고 개선하는데 도움이 된다.

그림 1은 DeepEyes의 구성을 나타내는 그림이다. 여기서 (a)는 모형 평가에 사용되는 loss와 accuracy 그래프, (b)는 각 층의 활성화 값들을 확률로 변환한 히스토그램, (c)는 필요 없는 필터 찾기 위한 활성화 빈도 히트맵, (d)는 입력 이미지에 대한 필터의 활성화 값 시각화, (e)는 어떤 한 층에서의 필터들 간의 관계를 시각화 한 것이다. 이와 같은 정보들을 통하여 학습 과정에서의 각 계층들의 세부 정보를 알

* E-mail : sako@unist.ac.kr

울산과학기술원 | IP:114.70.9.*** | Accessed 2019/06/21 16:12(KST)

수 있고 이를 모델 평가와 개선을 위하여 사용할 수 있다. 효용성을 보여주기 위하여, 해당 툴을 사용하여 fine tuning을 수행 내용을 간략히 소개한다.

Fine tuning은 딥러닝 모델의 성능을 개선시키기 위한 하나의 방법으로써 먼저 학습된 모델의 특정한 계층을 추가적으로 학습시키는 방법이다. Fine tuning은 어렵고 시행착오가 많이 필요한 작업인데 시각화를 이용하면 어느 부분에서의 tuning이 필요한지 직관적으로 알 수 있다. 그림 2는 DeeyEyes를 이용하여 AlexNet이라는 1000여 개의 사물 구분 필터를 가진 모

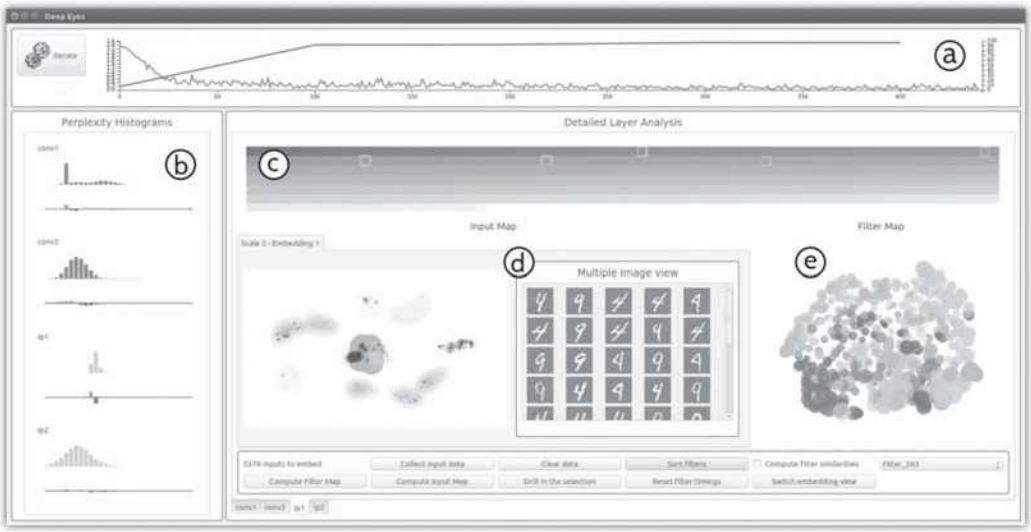

그림 1 DeepEyes 시각화 모델

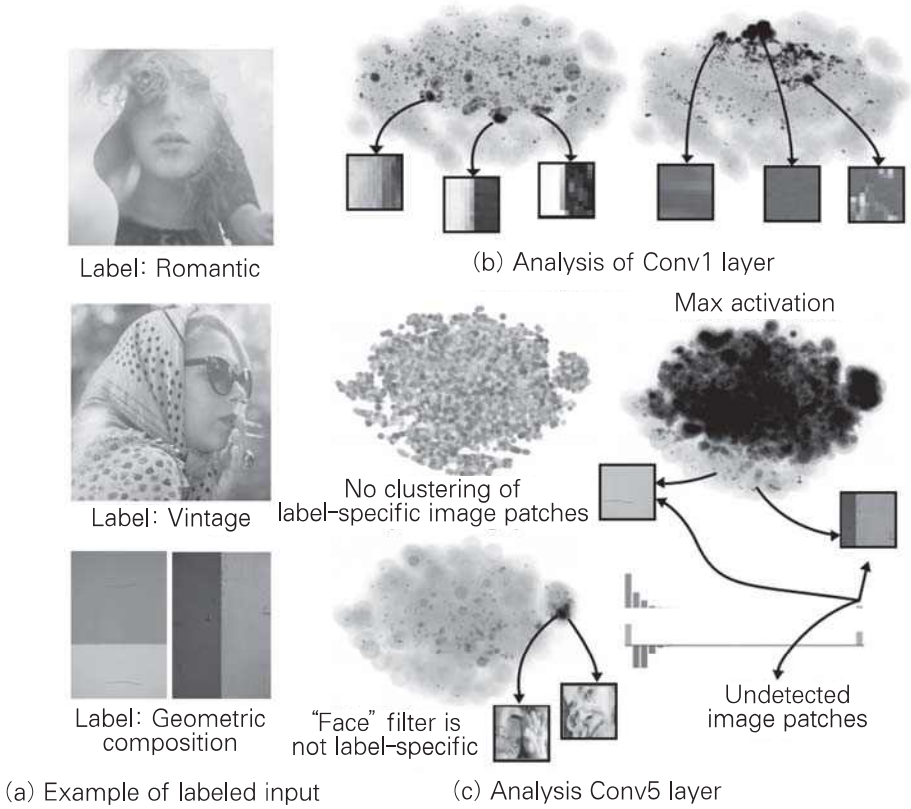

그림 2 DeepEyes를 이용하여 중요 필터 확인 가능한 fine tuning 과정

울산과학기술원 | IP:114.70.9.*** | Accessed 2019/06/21 16:12(KST)

형을 fine tuning을 통하여, 그림 2(a)의 romantic, vintage, geometric composition 등의 20개의 스타일로 구분 할 수 있는 필터를 지닌 모형으로 바꾸는 과정을 나타낸다. (b)에서 설명하는 바는, 첫 번째 층인 conv1은 주로 색과 모서리 특성을 잘 학습하고 있다는 것을 알 수 있는데, 이는 인터랙션을 통한 시각화에서, 필터가 파란색 필터끼리, 세로축 필터끼리 군집한 것을 알 수 있기 때문이다. (c)의 시각화가 함축하는 바는 여러 가지 인데, 이 모델은 레이블 별로 군집화가 되지 않는다는 것과 geometric composition 이미지들은 활성화를 거의 일으키지 않는다는 사실이다. 그리고 전혀 다른 스타일을 가진 두 가지 사람 얼굴 사진이 filter map에서 서로 가까이에 위치한 것이 시각화 되는데, 이는 원래 AlexNet이 사물을 분류하는 모형이란 점에서 야기된 것으로 판단된다. 위에서의 같이 시각화 시스템을 활용하여, conv5층은 모형의 성능에 전혀 기여하지 못하기 때문에, 삭제하는 것이 학습 속도 향상을 위해서라도 좋고, geometric composition 데이터가 더욱 많이 필요하다는 것과 인물 사진 데이터는 이 모델에서 오류가 발생하기 쉽다는 것 또한 알 수 있다.

3. RNN에 관한 시각적 해석

RNN(recurrent neural network)은 자연어 처리와 시계열 데이터 처리에 강점을 보이는 있는 딥러닝 모델이며, 이 모델 역시 내부의 은닉계층의 데이터 처리, 학습 과정 및 결과 예측 과정을 판단하기에 어려움이 있다. RNN 해석을 위하여, Ming과 그의 동료는 여러 RNN 모델의 은닉계층의 정보를 시각화하여 모델의 상태를 진단하고 구조 설계에 대한 이해를 돕기 위하여, RNNVis라는 새로운 시각화 툴을 제안하고[2], 해당 툴의 유용성을 RNN이 자연어를 처리 어떻게 하는지, 툴이 어떻게 이해도를 높여줄 수 있는지 보여줌으로써 증명한다. 예를 들어, RNN에서 단어 단위로 처리되는 은닉 계층의 메카니즘, 각 단어가 입력될 때, 전체 단어 분포 및 단어와 문장과의 관계에 기반을 둔 모델 학습 과정을 비교 설명한다.

RNNVis 크게 세 부분으로 구성되어 있다(그림 3). 왼쪽은 모델 매니저로 RNN 모델과 데이터셋을 관리한다. 가운데 evaluator 모듈은 모델 매니저로부터 받은 데이터를 가지고 처리하는 과정에서 RNN 은닉계층의 각 파라미터를 시간에 따라서 해석하고 클러스터링 한다. 오른쪽 visualization 모듈은 평가 부분에서 처리된 데이터를 받아 시각화 하는 부분이다. 이 시각화 모델은 은닉계층으로부터 받은 정보를 시각화를 통하여 시간단위로 해석할 수 있다.

그림 4는 RNN 모델중 하나인 LSTM의 마지막 계층을 클러스터링을 이용하여 시각화한 모습이다. A는 각 품사를 색깔로 대응시켜서 각각의 단어와 계층을 이어 합동 군집화(co-clustering) 시각화이다. B는 특정 단어에 대한 모델 응답 횟수를 나타낸 분포도이고(ex. when, where 응답 분포), C는 48번째와 123번째의 계층의 상태를 단어가 나오는 빈도를 이용하여 해석한 그래프이다. 위의 시각화 툴을 활용하여, 사용자는 어느 계층에서 어느 단어가 학습되고 출력되는지에 대한 경향성을 알 수 있고, 같은 품사의 비슷한 단어가 어떤 빈도로 사용되는지 확인 할 수 있다. 이는 곧 특정 모델이 데이터에 적합한지 확인하는데 기여를 하며, 모델의 개선 및 구현에 큰 도움이 된다.

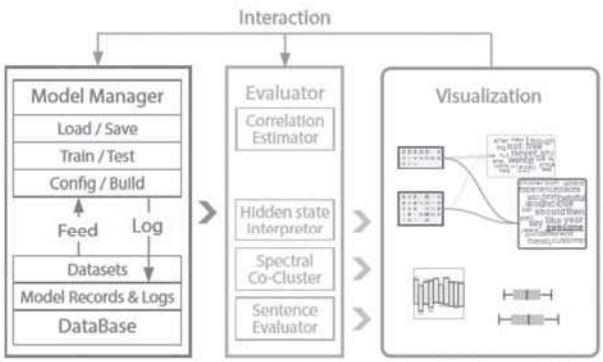

그림 3 RNNVis의 model manager, evaluator, visualization

울산과학기술원 | IP:114.70.9.*** | Accessed 2019/06/21 16:12(KST)

4. 산업계에서의 딥러닝 모델의 시각화

딥러닝은 다양한 산업 분야의 문제를 해결하는 돌파구로 각광을 받고 있으며, 컴퓨터 비전, 자연어 처리, 음성 인식, 자율 주행 등 많은 분야의 문제를 해결하기 위해 구글, 바이두, 인텔, 애플, 페이스북 등의 회사에서는 딥러닝에 대한 연구가 활발히 진행되고 있다. 이전 섹션과 같은 맥락으로, 산업계에서도 활용에 더하여, 딥러닝 모델이 어떻게 학습되고 결론이 도출되는지에 대해 이해하기 위해 노력하고 있으며, 그 가운데에 시각화 툴이 큰 역할을 하고 있다(ex. 구글 텐서플로[3]). 여기서는 페이스북에서 개발한 시각화 시스템인 ActiVis를 소개한다[4].

페이스북은 그동안 기존 프레임워크 활용한 코드기반 환경(command line interface)에서 딥러닝 작업을 수행했으나, 곧 이러한 방식은 직

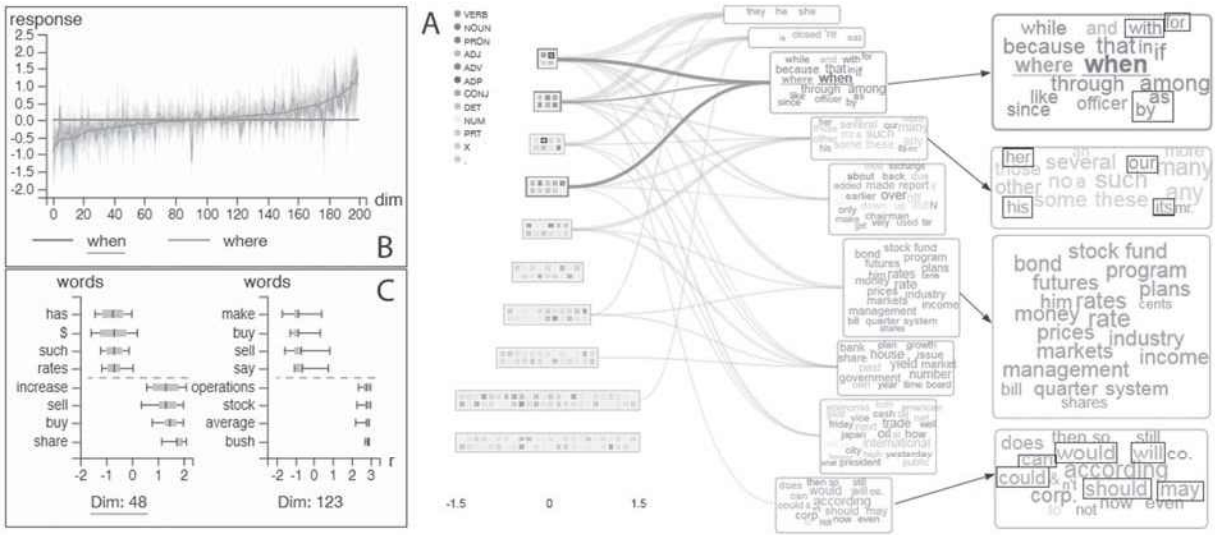

그림 4 LSTM-small의 마지막 계층 시각화 예

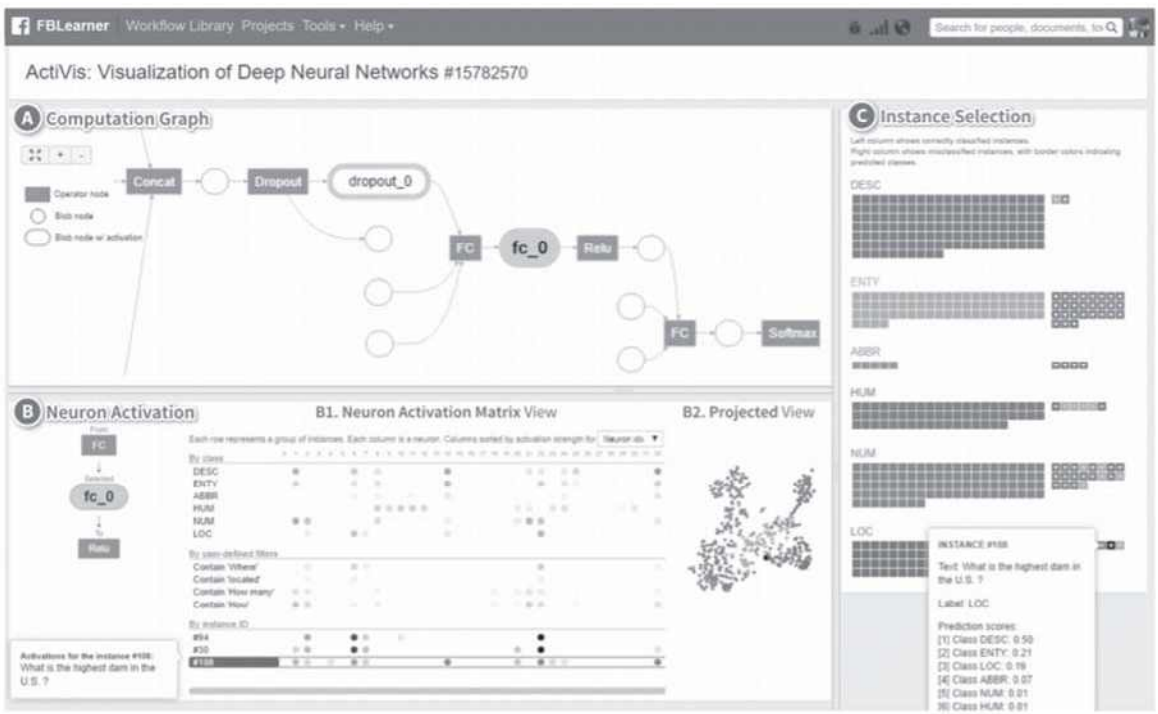

그림 5 ActiVis 시각화 모델

울산과학기술원 | IP:114.70.9.*** | Accessed 2019/06/21 16:12(KST)

관적으로 모델을 만들거나 이해하는데 어려움이 있다는 것을 인식했다. 따라서 여러 연구자들과 개발자, 그리고 데이터 분석가들이 모델을 개발하고 해석하기 위한 업무 프로세스를 개선하고자 하였으며, 그 결과로 ActiVis라는 딥러닝 시각화 툴을 개발하였다[4]. ActiVis는 개발 환경을 코드 기반인 CLI에서 GUI (graphic user interface)로 변화시켜, 딥러닝 전문가가 아닌 개발자들이나 분석가들도 모델을 유연하고 편리하게 만들거나 수정할 수 있게 하였고, 시각화를 통하여 학습 프로세스를 보여줌으로써 전체 모델이 어떻게 작동하는지 이해하는 데 큰 도움을 주도록 하였다. 뿐만 아니라 은닉계층들의 정보를 시각화를 이용하여 계층화하여 표현함으로써 인스턴스 기반과 하위 집합 기반의 분석이 가능하게 하였다.

그림 5는 ActiVis 시각화 시스템으로, 여기서 A는 모델 전체의 구조를 보여주는 그래프 시각화로, 각각의 구조를 탐색하기 위해서 구현되었다. B는 뉴런 활성화 패널 행렬 뷰로 활성화된 인스턴스로 하위 세트 및 클래스의 활성화 정도를 나타낸다. C는 인스턴스 선택 패널로 인스턴스와 그 분류 결과를 표시한다. 왼쪽에는 올바른 그리고 오른쪽에는 잘못 분류된 인스턴스를 시각화 한다.

5. 맺음말

딥러닝의 뛰어난 성능은 여러 분야에서 기존 문제를 해결할 돌파구로 인식되지만, 내부 프로세싱이 black-box라는 근본적인 문제로 인하여, 딥러닝이 도출한 결론을 사용자가 해석하고 믿기 어렵다는 문제가 존재한다. 이 문제를 시각화 기술을 통해 해결하고자 하는 노력이 인공지능 및 시각화 기술 학계에서 시작되고 있으며, 이 글에서 최근 발표된 시각화 시스템 및 기술에 대하여 살펴보았다. 아직 초기 단계이지만 시각화 기술을 활용하면 딥러닝 해석에 도움이 된다는 것이 여러 사례 분석을 통하여 나타나고 있으며, 점차 발전하는 시각화 기술은 딥러닝 결과 및 해석을 신속, 정확하게 도와줄 기술로 기계 분야에 딥러닝 적용 및 해석을 위하여 함께 고려해야 할 기술이다. KSNVE

참고문헌

(1) Pezzotti, N., Höllt, T., Gemert, J. V. et al., 2017, DeepEyes: Progressive Visual Analytics for Designing Deep Neural Networks, IEEE Transactions on Visualization and Computer Graphics (IEEE VIS 17), Vol. 24, No. 1, pp. 98~108.

(2) Ming, Y., Cao, S., Zhang, R. et al., 2017, Understanding Hidden Memories of Recurrent Neural Networks, In Proceedings of IEEE Visual Analytics Science and Technology (IEEE VIS 17).

(3) Wongsuphasawat, K., Smilkov, D., Wexler, J. et al., 2017, Visualizing Dataflow Graphs of Deep Learning Models in TensorFlow, IEEE Transactions on Visualization and Computer Graphics (IEEE VIS 17), Vol. 24, No. 1, pp. 1~12.

(4) Kahng, M., Andrews, P., Kalro, A. and Chau, D. H., 2017, ActiVis: Visual Exploration of Industry-scale Deep Neural Network Models, In Proceedings of IEEE Visual Analytics Science and Technology (IEEE VIS 17), Vol. 24, No. 1, pp. 88~97.

울산과학기술원 | IP:114.70.9.*** | Accessed 2019/06/21 16:12(KST)